

OpenCollab + GLM-5.2

SWE 委员会模式补测结果

实验整理

2026-06-30

1 截止口径

本报告汇总 SWE 委员会模式引入后，对 SWE-bench Lite 前 100 题中剩余 13 个未解样本的补测结果。评测结论只采用官方 SWE-bench harness 生成的 `report.json`。2026-06-30 晚间使用恢复后的 GLM-5.2 API 继续补齐 `django__django-11283`、`django__django-15252` 和 `django__django-15695`，三题均形成非空 patch 并完成官方评测。

截至本次补齐后，13 个剩余样本全部形成非空 patch 并完成官方评测，结果为 2 个通过、11 个未通过。所有已评测 patch 都能成功 apply，且没有 P2P 回归；未通过样本的失败均来自 F2P 残留。

在引入委员会模式之前，更新仓库补测后的前 100 题累计结果是 87/100。委员会模式本轮新增通过 `django__django-11019` 和 `django__django-14730` 两个样本。因此，前 100 题累计结果为 89/100。

口径	已通过	未通过	未评测
委员会补测的 13 个剩余样本	2	11	0
前 100 题累计，委员会补测后最终口径	89	11	0
前 100 题累计，全部样本已有官方报告	89	11	0

表 1: SWE 委员会模式补测后的总体结果

2 逐题结果

实例	状态	apply	F2P 失败	P2P 失败	patch 字符	首个失败信号或备注
<code>astropy__astropy-14365</code>	未通过	是	1	0	475	<code>test_roundtrip[True]</code>
<code>astropy__astropy-7746</code>	未通过	是	1	0	995	<code>test_zero_size_input</code>
<code>django__django-11019</code>	通过	是	0	0	5063	新增通过样本

实例	状态	apply	F2P 失败	P2P 失败	patch 字符	首个失败信号或备注
django__django-11283	未通过	是	1	0	921	rescued patch; auth proxy permission 迁移仍有 F2P 残留
django__django-11564	未通过	是	2	0	948	SCRIPT_NAME 下 static/media 前缀行为仍不完整
django__django-11630	未通过	是	2	0	1671	duplicate db table checks 仍有残留失败
django__django-11905	未通过	是	2	0	1119	isnull 非布尔值与 iterator 行为仍未覆盖
django__django-13321	未通过	是	18	0	787	session decode 相关失败较重
django__django-13768	未通过	是	1	0	911	send_robust logging 行为仍未满足
django__django-14155	未通过	是	3	0	1792	ResolverMatch repr 对 partial 的处理仍不足
django__django-14730	通过	是	0	0	1699	新增通过样本
django__django-15252	未通过	是	2	0	1391	rescued patch; TEST MI-GRATE=False schema 行为仍有 F2P 残留
django__django-15695	未通过	是	1	0	1993	rescued patch; unnamed index rename 仍有 F2P 残留

3 补齐样本说明

django__django-11283 的补齐运行围绕 django/contrib/auth/migrations/0011_update_proxy_permissions.py 形成 921 字符生产 patch。轨迹在 221 step、约 984,312 tokens 后已经完成结构化输出，但随后重新进入证据探索阶段。为控制成本，本次保留容器并抽取生产 diff 进入官方评测。官方评测结果为未通过，F2P 失败 1 个，P2P 失败 0 个。

django__django-15252 的补齐运行围绕 django/db/migrations/recorder.py 形成 1391 字符生产 patch。轨迹在 179 step、约 1,319,969 tokens 后已经完成结构化输出，但随后重新进入证据探索阶段。本次抽取生产 diff 后官方评测，结果为未通过，F2P 失败 2 个，P2P 失败 0 个。

django__django-15695 的补齐运行围绕 django/db/migrations/operations/models.py 形成 1993 字符生产 patch。轨迹在 137 step、约 677,096 tokens 后已经完成结构化输出，但随后重新进入证据探索阶段。本次抽取生产 diff 后官方评测，结果为未通过，F2P 失败 1 个，P2P 失败 0 个。

4 过度验证信号

三题都出现了同一种 workflows 现象：模型已经给出 Your task is complete 并留下可评测生产 diff 后，validation-council-solve 又进入新的证据探索或验证阶段。为避免继续消耗 GLM token，本次

在保留容器后手动停止，并只抽取生产源码 diff 进入官方评测。该现象说明委员会模式的退出条件仍需要改进：当最终验证已经记录结构化完成信号且工作树只剩允许路径时， workflow 应直接产出 patch，而不应重新启动下一轮证据探索。

三题补齐运行的 token 与 loop 信号如下。django__django-11283 使用约 984,312 tokens, loop mention 为 0; django__django-15695 使用约 677,096 tokens, loop mention 为 4; django__django-15252 使用约 1,319,969 tokens, loop mention 为 2。按 GLM-5.2 粗略价格下界缓存输入 0.26 美元/百万 token、上界全输出 4.4 美元/百万 token 估算，三题合计约 2,981,377 tokens, 成本区间约为 0.775–13.118 美元。

5 可复查性

主要 artifact 位于以下目录。委员会主批次在 eval_work/swe_committee_mode_remaining13_glm52_20260629; 第 12、第 13、第 3、第 4 题 targeted 补跑在 eval_work/swe_committee_targeted_12_34_8m_glm52_20260630; 本次第 4、第 13、第 12 题干净补齐在 eval_work/swe_committee_clean_rerun_4_13_then_12_glm52_20260630。第 4/13 官方评测摘要在 official_eval_phase1_4_13/summary_official_eval.json, 第 12 官方评测摘要在 official_eval_task12_rescued/summary_official_eval.json。本报告的 PDF 与 TeX 文件位于 docs/experiments/glm52-swebench-20260628/report。