

# OpenCollab SWE-bench V3 类复杂 Workflow 评测与 Harness 修复报告

Kai / Codex

2026-07-06

## 1 摘要

过去三天围绕 OpenCollab 在 SWE-bench 上的复杂 workflow 做了三件相互关联的工作。第一，复盘 V2 委员会和 V1 对比，确认 V2 的差结果里混入了结构化 agent 连接错误、schema 捕获失败、空 patch 与 official eval 自动化缺口。第二，设计并实现委员会 V3，把早期契约裁决后置，先做语义盘点、已有工具审查和判别性探针，再让求解器写补丁，最后由契约法庭裁决。第三，围绕 V3 16M 并发做题暴露出的异常，把评测 Harness 逐层补厚：模型代理断连、429、远端 tmux、Docker、SSH、checkpoint 恢复、sidecar patch、official eval 发现与状态分类都进入统一的可观测状态机。

这次最重要的结论是：复杂 workflow 的实验结果必须先经过 Harness 分层，才有资格用于架构比较。V2 的 0 resolved 和 V3 16M 的大批 invalid 都不能直接解释为“委员会思想失败”。这些结果首先说明，复杂 workflow 一旦包含多个结构化阶段、远端容器、代理转发和 official eval，任何一个基础设施错误都可能伪装成语义失败。近期修复的目标就是把这种伪装拆掉，让可恢复错误进入暂停状态，让无法恢复的技术失败单列，让 official unresolved 只表示 patch 已被官方评测判为未解决。

当前最新一轮 12 题 summary 来自 docs/monitoring/swe\_v3\_16m\_12\_summary.md，生成时间为 2026-07-06 04:29:50。记录显示 12 题中 official eval 完成 2 题，resolved 为 0，unresolved 为 2；Pro Lite 10 题没有进入 official eval，其中 6 题为运行层 infra invalid，4 题为空 patch invalid。代理账本窗口记录 input tokens 96,962,358，cached input tokens 74,813,952，output tokens 1,223,403，total tokens 98,185,761，估算费用 \$55.842369。12 题 checkpoint tokens\_spent 合计 58,736,780。这个 summary 记录的是修复前一波运行的结果，它直接推动了后续 checkpoint sidecar 和 infra pause 的加厚。

## 2 三天工作时间线

| 日期 | 主题 | 产出与证据 |
|----|----|-------|
|----|----|-------|

|            |                          |                                                                                                                                                                                                                                                                                                                                     |
|------------|--------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 2026-07-03 | V2/V1 对比与 V3 方案形成        | V2 11 题已有 10 个有效 patch 官方评测，结果 0 resolved / 10 unresolved。确认 <code>django__django-15252</code> 旧 invalid 源于连接错误和空 staged diff。整理 <code>django__django-11019</code> 上 V1 通过、V2 失败的语义差异，提出 V3 的 delayed contract judgement 设计。组会文档位于 <code>docs/group_meetings/2026-07-03-swebench-v2-harness/</code> 。                               |
| 2026-07-04 | V3 16M 并发与 checkpoint 试验 | 启动经典两题和 Swe Batch Pro Lite 前十题，连续暴露 DNS、容器名冲突、代理依赖本机、远端直连失败、容器现场无法恢复等问题。新增 <code>scripts/swe_parallel_start.py</code> 、 <code>scripts/swe_v3_wave_watchdog.py</code> 、 <code>scripts/swe_auto_eval_driver.py</code> 的多 run 监控与自动 official eval 能力。                                                                                  |
| 2026-07-05 | 单题强监督与 12 题 summary      | 抽 <code>django__django-11019</code> 单题重新做，验证单题在强监督下能生成 patch 并完成 official eval，但 V3 patch official unresolved。随后尝试剩余 10 题并行，生成最终 summary：2 题 official eval unresolved，Pro Lite 10 题均未完成 official eval，暴露 checkpoint 恢复没有保存容器 diff 的关键缺陷。                                                                                            |
| 2026-07-06 | 可恢复暂停语义与 checkpoint 加厚   | 修改 workflow runtime、evaluator、gen prediction 和 watchdog。可恢复 infra 错误进入 <code>infra_paused</code> ；checkpoint 写入 <code>checkpoint.worktree.patch</code> sidecar；异常捕获时强制保存 runtime checkpoint；恢复前探测当前 worktree；checkpoint diff 排除 SWE-bench 注入测试文件；旧格式 metrics 的 nested failure counts、429 pause reason 和 Docker/tmux infra 日志识别均已补上。 |

3 实验状态与当前证据

3.1 V2 十一题与 V1 对比

V2 11 题第一轮最醒目的数字是 10 个有效 patch 全部 official unresolved。更细的看板显示，这一轮不能直接用于 V1/V2 架构胜负判断，因为失败里混入了 infra invalid 和 workflow incomplete。V2 的多个 incomplete 样本在 final verifier、existing-tests、diff-risk、post-validation 等结构化阶段出现

Connection error。旧 runtime 把结构化输出缺失转成默认 blocker，导致基础设施错误伪装成 semantic blocker。

| 指标                             | 数值                                         | 解释                                      |
|--------------------------------|--------------------------------------------|-----------------------------------------|
| V2 目标样本                        | 11                                         | 原始 V2 对比样本                              |
| 有效 patch official eval         | 10                                         | django__django-15252 原始为空 patch invalid |
| official resolved / unresolved | 0 / 10                                     | 已评测 patch 均未解决                          |
| P2P fail                       | 0                                          | patch 均可 apply，失败集中在 F2P 残留             |
| V1 主报告                         | 2 pass / 8 fail / 3 uneval                 | 后续 rescued 的 3 个 uneval 均补评为 unresolved |
| V1 solved 两题                   | django__django-11019, django__django-14730 | 后续作为经典两题用于 V2/V3 回归试验                   |

django\_\_django-11019 是这三天最有解释力的样本。V1 使用 Django 内已有的 `stable_topological_sort()`，能满足稳定交错排序。V2/V3 多次手写合并或拓扑规则，能通过题面局部例子，却漏掉 `Media.merge([1,2],[3,4]) == [1,3,2,4]` 这一类判别性 probe。这个样本说明，增加评审角色会放大证据质量问题；如果早期没有足够多的语义盘点和已有工具审查，后续契约裁决会围绕错误假设形成稳定共识。

3.2 V3 16M 12 题结果

V3 16M 12 题由两道经典题和 Pro Lite 前十题组成。两道经典题各自单题运行并完成 official eval，结果均 unresolved。Pro Lite 前十题没有进入 official eval，其中 4 题最终为空 patch invalid，6 题为 infra invalid 且保留了非空 patch。这个结果的直接意义是：V3 的求解质量还没有得到有效评估，因为多数样本停在做题 Harness 层。

Pro Lite 10 题的 token 使用很高，但没有得到对应的 official eval 结果。代理账本窗口显示 5,197 条记录，其中成功 4,695 条、错误 502 条，total tokens 接近 98.19M。这说明并行做题的瓶颈已经超出速度本身。只要 checkpoint、代理、容器恢复和 official eval 任一环节不稳，大规模并发会把错误放大成费用和时间浪费。

| run                        | 题数 | eval 完成 | resolved | unresolved | 说明                                                                |
|----------------------------|----|---------|----------|------------|-------------------------------------------------------------------|
| classic_single_django11019 |    | 1       | 0        | 1          | patch 6784 字符, workflow 侧仍带 infra invalid 标记, official unresolved |
| classic_single_django14730 |    | 1       | 0        | 1          | patch 1813 字符, official unresolved                                |
| prolite10_checkpoint       | 10 | 0       | 0        | 0          | 6 个 infra invalid, 4 个 empty patch invalid, 均未进入 official eval    |

4 差结果带来的核心发现

4.1 transport failure 会污染语义状态机

结构化 agent 是 V2/V3 复杂 workflow 的基本通信单元。每个 `ctx.agent(..., schema=..., label=...)` 都承担一个语义节点，例如 task intake、semantic inventory、helper audit、candidate contracts、post validation、skeptic、final tribunal。旧 runtime 遇到 Connection error、API timeout、代理不可达或反向隧道断开时，结构化结果常常变成 `None`。workflow 随后用默认 fallback 把 `None` 解释成 verifier fail 或 concrete blocker。这样，网络错误进入了语义状态机。

修复后的原则是：只有模型成功返回结构化 verdict，workflow 才能走语义状态机边；transport 或 rate limit 错误先在同一 label 原地重试，重试耗尽后进入 infra 类状态。这个原则后来也扩展到生成层：远端 Docker、tmux、SSH 这类可恢复基础设施错误也进入暂停状态，不能被当作最终失败。

4.2 checkpoint 只保存阶段名没有保存工作区

V3 16M 并发暴露了更严重的问题。旧 checkpoint 保存了 workflow 阶段和若干结构化产物，但没有可靠保存容器里的 worktree diff。watchdog 续跑时可能新起一个干净容器，workflow 从 checkpoint 认为自己已经进入后段，真实文件系统却没有前面 coder 写过的补丁。于是日志里出现 `workflow: tokens=0 steps=0, staged diff empty, git status clean`，最后变成 empty patch invalid。qutebrowser、teleport、navidrome 等 Pro Lite 样本都出现过这种症状。

这次修复把 checkpoint 从“语义状态”扩展为“语义状态 + 工作区 diff”。`WorkflowContext.checkpoint_put()` 每次写 `checkpoint.json` 时，会用临时 index 捕获容器当前 diff，并写到 `checkpoint.worktree.patch`，同时保存 `checkpoint.worktree.json` 元数据，包括 sha256、字节数、stage、git status 和 HEAD。恢复时先探测当前 worktree，若当前 diff 为空才 apply sidecar；若当前 diff 已经非空，就跳过二次 apply，避免覆盖现场。

### 4.3 SWE-bench 注入测试会污染 checkpoint diff

更深一层的边界来自 SWE-bench 的测试注入。做题时 evaluator 会先把官方 `test_patch` 注入容器，让模型可以跑目标测试。最终抽 patch 前会把这些注入测试文件清掉，防止提交 patch 里混入测试。但 checkpoint diff 捕获发生在 workflow 中间，如果直接 `git add -A`，sidecar 会把注入测试也保存进去。

这会造成恢复误判。下一次新容器启动后，测试文件会再次注入；恢复 sidecar 前探测到 worktree 非空，于是以为当前已经有模型修改，跳过 sidecar apply。结果真正的补丁没有恢复，后续仍可能得到空 patch。修复后，WorkflowContext 接收 `injected_paths`，checkpoint diff 命令在临时 index 中对这些路径执行 `git reset -q HEAD -- <path>`。这样 sidecar 只保存模型真实修改，不保存官方测试注入文件。

### 4.4 official eval 需要纳入做题状态

生成 patch 之后还没有完成一道题。official eval 发现、启动、状态刷新、report 读取和技术失败分类都必须由脚本管理。否则就会出现“有 patch 但没人评”“eval 已完成但 report 没找到”“tmux 已退出但状态仍 active”“dataset 单对象 JSON 触发 eval 启动失败”等实际问题。

`scripts/swe_auto_eval_driver.py` 现在承担自动 official eval。它读取 `predictions.jsonl`，按 patch sha 创建 side-car，启动 official eval tmux，轮询 report，写 `status.json/status.md`。它也会识别活跃生成会话，避免 patch 未完成时抢跑 eval。对 Pro Lite 数据集，它支持 `instances.jsonl` 发现和单题 dataset 规范化。对 technical eval failure，它会有有限重试，仍失败后保留日志和状态。

## 5 V3 复杂 Workflow 设计

V3 的关键改变是契约裁决后置。早期阶段只做观察、盘点和假设，不给最终裁决。只有当判别性探针、补丁后验证、diff 风险分析和最终怀疑者都给出证据后，最终契约法庭才输出通过、重试或 `invalid`。

| 阶段     | 输入              | 产物                  | 约束              | 下一步             | 失败处理               |
|--------|-----------------|---------------------|-----------------|-----------------|--------------------|
| 任务接入   | issue 文本与 hints | 复现摘要、相关路径、未知点       | 只盘点，不裁决         | 语义盘点            | 缺结构化输出时重试          |
| 语义盘点   | 任务框架、仓库事实       | 行为事实、公开测试、兼容边界      | 证据必须指向文件或命令     | 工具审查            | transport 进入 infra |
| 已有工具审查 | 语义盘点            | 可复用 helper、手写风险     | 必须搜索仓库原生工具      | 候选契约            | 工具缺口进入 unknown     |
| 候选契约   | 语义事实与 helper    | 硬契约、假设、未知项          | 不能把未知项升级成硬契约    | 探针包             | 证据不足时后续回退          |
| 判别性探针  | 候选契约            | 能击败浅层错误解法的 probe    | 至少覆盖一个反例扩展      | 求解器             | 探针不足触发重试           |
| 求解器    | 契约、探针、反馈        | 源码 patch            | 可写代码            | 后置验证            | 写后保存 checkpoint    |
| 最终法庭   | patch 与验证证据     | 通过、重试、infra invalid | 缺 coverage 禁止放行 | 输出 patch/report | 可恢复错误暂停            |

这个设计直接来自 `django__django-11019`。如果先让契约委员会在信息不足时决定一切，系统很容易把题面局部例子当成完整契约。V3 改为先盘点文档、代码和现有工具，再生成候选契约，再用判别性 probe 反驳弱契约。最终裁决仍然存在，但它的输入必须包含覆盖证据，而非只听多个 agent 的口头赞成。

6 Harness 修复明细

| 修复点                         | 旧问题                                                      | 当前行为                                                                                                               |
|-----------------------------|----------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------|
| 结构化 stage retry             | Connection error 后返回 None，被 workflow 当成 semantic blocker | 同一 label 原地重试 10/30/90 秒，耗尽后抛 WorkflowInfraError                                                                   |
| 错误分类                        | transport、schema、semantic blocker 混在一起                   | metrics 记录<br>transport_error_count、<br>rate_limit_error_count、<br>schema_failure_count、<br>semantic_blocker_count |
| 429 分类                      | 429 被压成普通 transport                                      | _transport_infra_error_type()<br>把 429 标成 rate_limit_error，<br>pause reason 保留类型                                   |
| checkpoint worktree sidecar | checkpoint 只保存 workflow 阶段，不保存容器 diff                    | 写 checkpoint.worktree.patch 与元数据，恢复时 apply sidecar                                                                 |
| 异常时强制 checkpoint            | coder 已改代码、后置验证断连时可能没走到<br>_save("solve:r")              | evaluator 捕获 budget、infra、<br>timeout、普通异常时写 _runtime<br>checkpoint 并捕获当前 diff                                     |
| 注入测试排除                      | sidecar 可能保存官方 test patch，恢复时被注入测试误导                     | checkpoint diff 命令对 injected paths 从临时 index 中 reset                                                               |
| 空 patch 覆盖保护                | 续跑后干净容器可能覆盖前面非空 patch                                    | 抽 patch 为空时尝试 sidecar 恢复；<br>sidecar 不可用时标记<br>checkpoint_sidecar_unusable                                         |
| 暂停状态                        | 可恢复错误会进入 invalid 或 technical failed                      | infra_paused 单列，watchdog 不把它计入完成数，健康恢复后<br>--resume                                                                |

|                      |                                         |                                                                       |
|----------------------|-----------------------------------------|-----------------------------------------------------------------------|
| Docker/tmux infra 识别 | 远端基础设施异常被写成 generation technical failed | generation log 中的 Docker daemon、tmux、SSH、端口冲突、磁盘不足等标成 infra kind，进入暂停 |
| official eval 自动化    | 有 patch 后需要人工启动和查 report                | swe_auto_eval_driver.py 自动发现 patch、启动 eval、刷新状态、处理 report 路径漂移        |

7 暂停与继续的真实边界

新的统一规则是：凡是修复后可以继续的情况，外层状态进入 `infra_paused`，不进入最终错误。日志会保留原始错误，但 `summary` 不能把它算成语义失败或最终技术失败。这个规则覆盖模型代理断连、429、远端代理健康检查失败、SSH 反向隧道断开、Docker daemon 连接失败、tmux 异常、端口冲突和磁盘不足等可恢复问题。

| 场景                             | 当前状态                                                                                  | 恢复方式                                         |
|--------------------------------|---------------------------------------------------------------------------------------|----------------------------------------------|
| 结构化 agent<br>Connection error  | <code>infra_paused</code> 或 <code>infra_invalid</code> ，由 <code>retryable</code> 字段决定 | 代理健康后 watchdog 续跑同题，workflow 从 checkpoint 恢复 |
| 429 / rate limit               | <code>infra_paused</code> ，pause reason 为 <code>rate_limit_error</code>               | 等待冷却窗口，随后 resume                             |
| Docker daemon / tmux / SSH 异常  | <code>infra_paused</code>                                                             | watchdog 等待或修复远端代理后重新启动生成                    |
| 已有 checkpoint 且有 sidecar patch | <code>recoverable_checkpoint</code> 或 <code>infra_paused</code>                       | 新容器恢复 sidecar diff，再继续 workflow              |
| sidecar apply 失败               | <code>checkpoint_sidecar_unusable</code> ，保留日志                                        | 需要人工排查 base commit、注入测试或 patch 兼容性           |
| 官方评测 tests fail                | <code>official_unresolved</code>                                                      | 这是 patch 语义结果，进入算法分析                         |

需要诚实说明的是，当前恢复接近“checkpoint 后无损”，还不能覆盖所有物理中断。若 Python 进程被直接杀死、机器掉电、Docker 容器瞬间消失，且中断发生在任何 checkpoint 写入之前，那段 agent call 和尚未写入的 diff 仍可能丢失。若模型请求已经发出但响应未回来，token 流也无法从中间继续，只能从上一个 checkpoint 重新发起下一步。这个边界在报告中必须保留，因为它决定了下一轮是否需要更细粒度的工具级事件日志、周期性 worktree snapshot 或外部 supervisor。

8 V3 当前科研判断

V3 的设计方向仍然有意义，但当前 12 题结果无法证明 V3 求解能力。理由很直接：Pro Lite 10 题全部停在 Harness 层，两道经典题虽完成 official eval，但结果均 unresolved，其中 django\_\_django-11019 继续暴露了“工具审查和判别性 probe 仍需加强”的问题。V3 的收益需要在 Harness 稳定后用消融实验验证，而非只看完整 V3 与 V1 的二元对比。

下一轮建议比较五个条件：V1；V1 加 observable inventory；V1 加三路 diff-risk；V1 加 final skeptic；完整 V3。每个条件统计 resolved、F2P fail、P2P fail、patch rate、workflow done rate、infra paused/invalid rate、token input/output/cached、内部 verdict 与 official eval 的一致率。这样才能判断 V3 的哪个模块真正增加成功率，哪个模块只增加成本或失败面。

9 当前文件与证据路径

| 路径                                                         | 内容                                                                                  |
|------------------------------------------------------------|-------------------------------------------------------------------------------------|
| docs/monitoring/swe_v3_16m_12_题量终summary                   | 12 题量终summary，包含 98.19M token 窗口、2 题 official unresolved、Pro Lite 10 题 invalid 状态   |
| docs/monitoring/swe_v3_16m_12_题量终summary                   | Pro Lite 10 题 invalid 状态，记录 active、patch、workflow status、error counts 与 proxy usage |
| docs/monitoring/swe_v2_11019_django__django-11019_analysis | django__django-11019 analysis 语义差异分析                                                |
| opencollab/opencollab/application/workflow                 | 结构化/workflow 错误分类、checkpoint sidecar、rate-limit 分类、injected path 排除                 |
| opencollab/opencollab/harness/evaluator                    | 异常捕获、runtime checkpoint、checkpoint 恢复接入                                             |
| swebench/gen_prediction_workflow.py                        | checkpoint 恢复、防空 patch 覆盖、metrics 状态拆分                                              |
| scripts/swe_v3_wave_watchdog.py                            | 3 步 run watchdog，暂停/恢复状态、远端代理修复、summary 写入                                          |
| scripts/swe_auto_eval_driver.py                            | 自动 official eval、side-car 管理、report 发现和状态刷新                                         |

10 结论

最近三天的主要进展集中在复杂 workflow 的评测系统升级：它从“靠人工盯跑的实验脚本”演进为“能区分语义失败、基础设施失败、可恢复暂停、空 patch 和官方评测结果的做题框架”。V2 的差结果揭示了结构化通信错误会污染语义判断；V3 的并发失败揭示了 checkpoint 不能只保存阶段名，还必须保存容器工作区 diff；经典两题揭示了委员会需要后置契约裁决和更强判别性 probe。

现在可以继续推进下一轮实验，但前提是新 summary 中 infra\_paused 不再被当作结束，checkpoint sidecar 可恢复性必须先通过单题 smoke。建议先用 django\_\_django-11019 或 Pro Lite 中已有非空

patch 的一个样本做恢复测试：人为中断代理或 tmux，确认 watchdog 进入 `infra_paused`；恢复代理后确认 `--resume` 应用 `checkpoint.worktree.patch`；最终确认非空 patch 自动送入 official eval。这个 smoke 通过后，再重新跑 Pro Lite 10 题或更大的消融实验。